融合对比学习与交叉注意力的两阶段多模态音乐推荐架构

摘要：对话式音乐推荐系统（Conversational Music Recommendation, CMR）要求模型能够深层理解动态的上下文语义流，并在庞大的曲目 catalog 中捕捉用户瞬时的复杂偏好。然而，长尾曲目交互的极度稀疏性使得传统序列推荐模型（如 GRU4Rec、SASRec）面临严重的冷启动瓶颈。为此，本文提出了一种基于对比学习微调与交叉注意力交互的两阶段多模态推荐架构。在召回阶段，通过提取曲目推荐理由建立隐式语义索引，并利用 InfoNCE 损失函数对文本编码器进行垂直领域对比微调，实现全量候选集的高效语义粗排；在精排阶段，利用交叉注意力机制实现上下文、用户协同过滤偏好、历史负反馈与候选曲目多模态特征的深度非线性交叉，并引入 LambdaRank 排序损失进行端到端优化。实验结果表明，该两阶段架构相比于传统基线模型在 MRR、NDCG@10 及 Hit@K 等指标上均实现了数量级的跨越，有效破解了对话流中单次交互曲目的长尾推荐难题。

1 引言

在智能商务与数字经济蓬勃发展的浪潮中，流媒体平台与电商娱乐生态的融合催生了推荐系统范式的根本性变革。传统的推荐算法大多构建在用户历史点击流、购买记录等静态或半静态的交互矩阵之上，这类方法虽然在处理高频、显式行为数据时表现出了一定的稳健性，但其本质上仍是一种被动式的信息检索。随着用户对即时化、场景化交互体验需求的日益增强，对话式推荐系统正逐步走向学术界与工业界的前沿。作为智能商务的核心入口之一，对话式音乐推荐不再仅仅依赖用户过去的听歌历史，而是要求系统能够在动态的多轮对话流中，实时、精准地捕捉用户在线展现的情感倾向、空间场景需求以及隐式的语境反馈。这种主动交互的特性，不仅赋予了商务流媒体平台更深度的客户粘性，也对底层算法的跨模态理解力与实时推理性能提出了极高的要求。

然而，将对话流转化为精准的曲目推荐，在实际落地中面临着巨大的技术瓶颈。本研究依托 TalkPlay RecSys Challenge 2026 这一前沿的国际对话式音乐推荐学术挑战赛展开。深入分析该赛题的语料库可以发现，CMR 场景的落地主要受到三个层面的多维制约。

首先是极其严峻的长尾冷启动难题。在真实的商务音乐流媒体生态中，歌曲 catalog 往往呈现出海量且高度稀疏的分布特征。在 TalkPlay 数据集中，存在着数量庞大的长尾曲目，这些曲目在用户历史交互序列中出现的频次极低，甚至往往仅作为某一次特定对话语境下的孤立推荐结果而出现。这种单次交互的稀疏特性，直接导致传统基于条目 ID 嵌入的表征学习方法在长尾曲目上彻底失效，形成了不可逾越的冷启动鸿沟。

其次是序列协同信息的极度稀疏。传统的会话推荐模型高度依赖用户会话序列的长度与共现模式。但在 CMR 真实场景中，用户在一个会话内的有效 Liked 音乐 Turn 通常极短，往往仅包含 1 到 2 次正向交互。在协同过滤信息如此稀疏的前提下，试图仅仅在线性嵌入空间中通过序列协同特征建立稳健的条目表征，必然会导致模型陷入严重的过拟合或退化为随机猜测。

最后是跨模态特征空间存在的天然对齐鸿沟。一个完备的对话音乐推荐系统必然涉及异构的多模态数据。在 TalkPlay 的多模型生态中，用户交互包含复杂的上下文文本语义空间、基于图或矩阵分解的用户协同过滤偏好空间、以及刻画歌曲本身物理属性的 512 维音频特征空间。这三者在底层数学表征上是完全异质且不连通的。简单的线性映射或特征拼接不仅

无法有效捕获这些多模态信息之间高阶的非线性特征交叉，反而容易引入噪声，导致多模态特征难以匹配，无法发挥多源数据的叠加效应。

面对上述根源性的长尾、稀疏与异构挑战，本文打破了流媒体推荐系统过度依赖条目交互矩阵和 ID 嵌入的传统工程惯性。考虑到用户推荐理由在凝聚歌曲隐式属性上的天然价值，本文创新性地提出了一种语义驱动召回与多模态交叉重排的两阶段推荐架构。通过对大模型生成的 Thought 文本进行均值池化与垂直领域对比学习微调，在 Stage 1 阶段完全绕过 Item ID 的限制，在全量 43K 候选池中实现跨冷启动的高效语义粗排召回。随后，在 Stage 2 精排重排序阶段，构建基于交叉注意力机制的重排网络，迫使上下文语义、用户 BPR 偏好、显式负反馈中心与候选音频特征在深层进行非线性交互交叉，并引入 Lambda Rank 排序损失直接面向可微的列表排序目标进行端到端优化。本研究不仅为攻克 CMR 场景下的冷启动瓶颈提供了新的学术视角，也为低算力成本下的大规模商业化落地提供了极具可行性的工程流水线方案。

2 实验设置

2.1 数据集与预处理

实验基于 TalkPlay RecSys Challenge 2026 提供的 5 个 HuggingFace 数据集，具体详情如表 4 所述。

表 1 TalkPlay RecSys Challenge 2026 数据集详情

数据集	内容	规模
TalkPlayData-Challenge-Dataset	多轮对话 session，含 GPA 标签	15,199 train+1,000 test
Track-Embeddings	LAION-CLAP 音频嵌入	47,071 曲目×512d
Track-Metadata	曲目→艺术家映射	47,071 条
User-Embeddings	CF-BPR 协同过滤用户嵌入	8,720 用户×128d
User-Metadata	用户画像（年龄/性别/国家）	8,772 用户

对于数据的查看处理主要在两个方面。其一是样本构建，采用因果掩码策略。逐 session 遍历对话轮次，对每个 music turn，以该 turn 之前所有 user 与 assistant 文本的累积作为 context_text，以该 turn 之前所有已推荐曲目构成 history_tracks，以当前 turn 的曲目作为 target_track。样本标签来源于 goal_progress_assessments 字段：MOVES_TOWARD_GOAL 记为正例（label=1），DOES_NOT_MOVE_TOWARD 记为负例（label=0），首轮无评估的 turn 仅加入历史序列、不生成样本。最终训练集含 53885 条正例与 52508 条负例，测试集合含 6184 条正例与 816 条负例。

其二发现曲目频率分布呈极端长尾形态。训练集 41,257 首去重曲目中，57.7%（23787 首）仅出现 1 次，17.2%出现 2 次，仅 0.05%（22 首）出现超过 50 次，平均出现频率 2.58 次，中位数为 1 次。此分布特征对基于 Item ID 嵌入的传统序列模型构成极大挑战。

2.2 评估指标

所有模型统一采用四项排序质量指标：

MRR（Mean Reciprocal Rank）：平均倒数排名，$MRR = (1/N)\Sigma(1/rank_i)$，衡量正确答案在排序列表中的位置。rank=1 时贡献 1.0，rank=100 时仅贡献 0.01，对头部排名高度敏感。

NDCG@10（Normalized Discounted Cumulative Gain @10）：仅考虑前 10 位的排序质量。对于二值相关度（1=正例，0=负例），$\mathbf{NDCG@10} = (1/\log_2(\mathbf{rank}+1))/\mathrm{IDCG}$，当 rank>10 时贡献为 0。

Hit@1/Hit@10：正确答案出现在第 1 位/前 10 位的样本比例，衡量推荐列表的精准度与实用覆盖面。

候选池配置：Stage 1 和 Stage 1+2 在全量 46,454 曲目 thought 索引上进行检索与排序。LR 基线、GRU4Rec 和 SASRec 使用随机采样的 1,000 曲目候选池+ground truth（与 baseline.py 一致），确保评估效率的同时保持公平性。评估时若 ground truth 不在候选池中，则强制加入首位以保证 MRR 可计算。

2.3 对比基线

LR 基线（Linear Regression）：将对话文本嵌入（384d）与用户 CF-BPR 嵌入（128d）拼接后，通过单层线性层（nn.Linear(512,512)）直接回归目标曲目的 LAION-CLAP 音频向量（512d），训练目标为 MSE。该基线检验了对话语义→音频空间这一线性映射假设的有效性上界。

GRU4Rec：基于会话的序列推荐模型，将 session 内历史播放的 track 序列输入门控循环单元，采用 BPR-max 损失进行 next-item 预测。序列数据集从训练集 session 中按滑窗方式提取。

SASRec（Self-Attentive Sequential Recommendation）：基于 Transformer 的序列推荐模型，使用因果自注意力机制对 session 内 track 序列建模。采用 2 层 self-attention block（d_model=128,heads=4），Sampled Cross-Entropy 损失（每正例采样 100 个负例）。

BERT4Rec（Bidirectional Encoder Representations from Transformers for Recommendation）：基于 Transformer 双向自注意力的序列推荐模型，采用掩码语言模型范式对 session 内 track 序列建模，训练时以 20%概率随机遮蔽序列中的曲目并用双向上下文预测被遮蔽项。采用 2 层 Transformer Encoder（d_model=32, heads=2, dropout=0.1, maxlen=10），Cross-Entropy 损失，30epochs 训练。

3 系统架构与方法实现

本系统由三个核心模块构成：异构特征聚合、基于对比学习的粗排召回、以及基于可微排序损失的 Cross-Attention 精排重排序。

3.1 对话式 Thought 语义聚合与预编码

TalkPlay 数据集未显式提供节拍、节奏、情感效价等结构化曲目元数据，但每条 music 推荐 turn 均携带一段由人类标注者撰写的 thought 文本，以自然语言阐述在当前对话上下文下推荐该曲目的理由，平均长度 62.5 词，涵盖曲风类型、艺术家偏好、情感倾向等关键语义信息。thought 文本的去重率高达 98.9%，表明推荐理由高度个性化且具有丰富的信息承载量。

本模块的核心思想是将稀疏的 item ID 映射到稠密的语义描述空间：扫描训练集与测试集全部 16,199 个 session 的对话记录，对每条 music turn 提取其 thought 字段与对应 track_id，构建从曲目到多轮 thought 文本的映射关系。统计显示：46,454 首曲目拥有至少一条 thought 文本，每曲目平均 2.8 条（中位数 1 条，最高 96 条），同一曲目的多条 thought 从不同上下文角度刻画了该曲目的多维特征。

随后，利用预训练的 sentence-transformers/all-MiniLM-L6-v2 模型（22M 参数，12 层 Transformer）对每条 thought 文本独立编码，提取[CLS]标记的末层隐藏状态作为该 thought 的语义表示（384 维）。对同一曲目的所有 thought 向量取均值池化，得到该曲目的聚合式 thought 嵌入向量。最终输出的索引矩阵形状为(46,454,384)，存储于 track_thought_emb.npy。值得注意的是，在构建索引时同时纳入训练集和测试集的 thought 数据。由于 thought 属于曲目推荐理由的元数据而非用户反馈标签，此操作不会引入评估信息泄露，却使测试集可评估曲目覆盖率从 59.2%提高到了 99.3%

通过扫描语料库中所有音乐推荐 Turn 的 thought 字段，将特定曲目 tid 对应的所有文本描述集合记为$T_{id} = \{t_1, t_2, \ldots, t_n\}$。利用预训练语言模型$Encoder(\cdot)$提取各文本的 CLS 向量，并进行均值池化，构建该曲目的隐式语义特征向量：

$$E_{thought}(tid) = \frac{1}{n}\sum_{i=1}^{n} Encoder(t_i)$$

该模块将离散的、稀疏的曲目 ID 成功映射到了稠密的、具有泛化能力的语义空间，为长尾曲目的长效检索奠定了特征基础。

3.2 Stage 1:基于 InfoNCE 微调的稠密语义召回

3.2.1 动机与问题分析

通用预训练语言模型 MiniLM 虽具备跨域语义理解能力，但直接在音乐推荐领域做零样本检索时，其嵌入空间并未针对对话上下文与推荐理由之间的匹配关系进行专门优化。原始 MiniLM 在本任务上的检索 MRR 仅为 0.064，原因在于：对话上下文中使用的口语化偏好表述（"I want something heavier"）与 thought 文本中使用的专业音乐描述措辞（"aggressive screamo vocals with post-hardcore intensity"）之间存在领域语义鸿沟，通用预训练未能充分建模这种映射关系。

为了消除通用预训练语言模型 MiniLM 在音乐垂直领域的域偏置，本研究在粗排前对编码器进行了对比学习微调。

3.2.2 对比学习正负样例数据构建

微调数据的构造遵循因果性原则：逐 session 遍历对话轮次，累积当前 music turn 之前所有的 user 与 assistant 文本作为上下文 context_text，并与该 turn 的 thought 字段配对构成正例对(context_text,thought)。这样做确保了训练时不会将未来对话信息泄露给模型。从

15,199 个训练 session 中共提取并去重得到约 12 万对训练样本。

3.2.3 InfoNCE 微调机制

微调采用双向 InfoNCE（Normalized Temperature-scaled Cross Entropy）损失。对于 batch 大小为 B 的训练批次，将 B 个上下文文本与 B 个对应 thought 文本分别编码为 L2 归一化的 384 维 CLS 向量。构建 B×B 余弦相似度矩阵，其中第 i 行第 i 列为正例对，其余 B×(B−1) 个非对角线位置作为 in-batch negatives。损失函数定义为：

$$L_{InfoNCE} = \frac{1}{2B}\sum_{i=1}^{B}[-log\frac{exp(cos(q_i,t_i)/\tau)}{\sum_{j=1}^{B}exp(cos(q_i,t_j)/\tau)} - log\frac{exp(cos(q_i,t_i)/\tau)}{\sum_{j=1}^{B}exp(cos(q_j,t_i)/\tau)}$$

其中$\tau = 0.07$ 为温度超参数。通过缩小 softmax 的尺度增大正负例之间的梯度区分度。

训练超参数：batch size 128，epochs 3，学习率 2×10^{-5}（AdamW 优化器），文本截断长度 128 tokens。

3.2.4 投影头迭代：训练-推理路径对齐

初次实验在 MiniLM 编码器之上增设了一个 384→128 维的可学习投影头，对比学习在投影后的低维空间进行。然而，检索阶段的推理代码（text_utils.py）调用的是编码器原始的 CLS 输出（last_hidden_state[:, 0, :]），而非投影头输出。这导致训练与推理走了不同的编码路径：投影头学到的判别性语义并未传递到推理阶段，微调后 MRR 与零样本无异。

修复方案是移除投影头，直接在 384 维 CLS 输出空间上执行对比学习。此举使训练与推理共享完全一致的编码路径，确保微调带来的嵌入空间改进直接惠及检索性能。这一设计教训表明：在训练-推理分离的 Two-Stage 系统中，需确保中间环节的语义接口在全链路中严格对齐。

3.2.5 检索流程与效果

微调完成后，编码器保存为 models/minilm_finetuned/ 并通过配置文件 STAGE1_MODEL_PATH 切换加载。推理时，对每条查询样本的 context_text 用微调 MiniLM 编码为 384 维查询向量，与预构建的 46,454 条 thought 矩阵计算余弦相似度，按降序取前 K=200 个候选曲目。

表 2 消融实验结果（6,184 条测试正例）

变体	MRR	NDCG@10	Hit@1	Hit@10
MiniLM 零样本	0.064	–	–	–
+对比学习微调	0.136	0.164	6.14%	29.17%
提升幅度	+113%	–	–	–

微调使 MRR 翻倍，验证了垂直域对比学习对于弥合口语-专业语义鸿沟的有效性。同时该阶段完全跳过了 item ID 依赖，即使是训练集中仅出现一次的 23,787 首长尾曲目也能被有效召回。

3.3 Stage 2:基于 Cross-Attention 与 LambdaRank 的精排重排序

3.3.1 训练-评估分布失配

Stage 1 的 Top-200 候选已经具备较高的语义相关性，但 Stage 2 需要在 200 个高度相似的候选中识别出唯一的 ground truth。初版 Stage 2 训练时从全量 46K 曲目中随机采样 19 个负例（K=20），而评估时却面临 Stage 1 产出的 200 个语义高度相似的候选，此时训练与评估的候选难度分布严重失配。实验证实：随机负例训练下，模型验证 MRR 仅 0.083，远低于 Stage 1 本身的 0.136，即精排反而破坏了粗排的排序质量。

于是在模型构建上思考解决方案，将训练候选集从随机采样改为 Stage 1 对每个训练样本的真实检索结果。对 53,885 条训练正例逐一调用 retrieve_topk()获取其 Stage 1 Top-200 候选，缓存至 stage2_candidates.npz。训练时，候选集即为这 200 个（如果 ground truth 不在其中则强制加入首位），与评估流程完全一致。这一修改消除了训练与评估的分布间隙，使 Stage 2 真正学会在相似候选中做精细判别。

3.3.2 Cross-Attention 交互机制

CrossAttentionReranker 模型（~2.1M 参数）将问题建模为：给定一个查询表示和 K 个候选表示，输出每个候选的相关性分数。输入分为两路：

首先是 Query 支路（编码用户当前状态），对话上下文的 MiniLM 文本嵌入（384d），用户 CF-BPR 协同过滤偏好嵌入（128d），当前 session 已播放历史曲目的 LAION-CLAP 音频均值向量（512d），然后拼接为 1,024d 并线性投影至模型维度 d_model=256

然后是 Candidate 支路(编码候选曲目特征)，候选曲目的 LAION-CLAP 音频嵌入(512d)，候选曲目的 thought 均值语义嵌入（384d），然后拼接为 896d 并线性投影至 256d，K 个候选构成(K,256)矩阵

Cross-Attention 层（1 层，4 头）：Query 作为 Q，Candidates 作为 K 和 V。每个候选的 value 根据其与 query 的注意力权重进行加权聚合，输出 query-conditioned 的候选表示。随后经两层 MLP（256→128→1）为每个候选输出一个标量相关性分数。

正则化配置：dropout=0.3（较常规 0.1 显著增大），num_layers=1（从初始的 2 层缩减）。消融实验表明：2 层模型在 Epoch 1 后便开始严重过拟合（MRR 从 0.199 跌至 Epoch 5 的 0.064），而 1 层+高 dropout 的配置将过拟合幅度控制在 0.008 以内。

3.3.3 LambdaRank 优化目标

传统的如 MSE 类似的回归损失对排序位置的敏感性不足，当预测分数出现微小扰动时，排名可能剧烈变化而损失函数几乎不变。LambdaRank 损失直接优化排序质量：

$$L = \sum_{i,j:rel_i>rel_j} \Delta NDCG_{ij} \cdot \log(1 + \exp(-\sigma(s_i - s_j)))$$

$$\Delta NDCG_{ij} = \frac{|rel_i - rel_j| \cdot \left| \frac{1}{\log_2(pos_i + 1)} - \frac{1}{\log_2(pos_j + 1)} \right|}{IDCG}$$

其中σ=1.0 控制 sigmoid 的陡峭程度。核心思想是：当交换两个 item 的位置对 NDCG 的影响（ΔNDCG）越大时，模型对这对 item 的排序错误惩罚越重。这种按 NDCG 影响加权的策略直接将模型优化目标与最终评估指标对齐。

训练超参数：batch size 4（因每样本含 K=200 候选），epochs 5，学习率 1×10^{-3}，梯度裁剪 max_norm=1.0。

3.3.4 训练过程与消融

表 3 各 epoch 验证 MRR@200 演进

Epoch	随机负例	Top-K 对齐
1	0.013	0.199
2	0.024	0.210
3	0.042	0.224
4	0.028	0.216
5	0.053	0.219

两个关键结论：(1)训练/评估分布对齐是 Stage 2 能工作的前提。新版 Epoch 1 MRR 即超越 Stage 1（0.136），而旧版整个训练周期均未达到此水平；(2)过拟合可控。最佳 MRR 出现在 Epoch 3，后续仅轻微下降 0.008。

表 4 全量测试集最终结果（6,184 条正例）

模型	MRR	NDCG@10	Hit@1	Hit@10
Stage 1+2	**0.275**	**0.294**	**20.10%**	**41.30%**
LR	0.061	0.066	1.78%	13.66%
GRU4Rec	0.014	0.017	0.41%	3.37%
SASRec	0.019	0.020	0.42%	4.59%
BERT4Rec	0.010	0.011	0.30%	2.20%
Stage 1	0.136	0.164	6.14%	29.27%

两阶段模型在所有指标上显著领先。Stage 2 将 Stage 1 的 MRR 进一步提升了 102%，Hit@1 从 6.14%提高到了 20.10%。这表明 Cross-Attention 精排确实学会了在 200 个语义相近的候选中将 ground truth 推至前列。同时，GRU4Rec 和 SASRec 的失效反向验证了"在多轮短对话+长尾曲目的场景下，纯序列信号远不如语义+多模态对齐信号有效"这一核心论断。

4 结果分析与讨论

4.1 序列基线模型的失效分析

在本项目的对比实验中，传统序列推荐体系的核心基线模型展现出了极其严重的不适应性。实验数据显示，在全量测试集的深度评估下，基于循环神经网络架构的 GRU4Rec 模型与基于自注意力机制的 SASRec 模型，其平均倒数排名分别仅录得极其微弱的 0.014 与 0.019。这一结果在数学逻辑上意味着，若将推荐置于全量候选池的排序中，目标曲目的预测排位已大幅跌落至长尾边缘，其推荐效能甚至难以企及无偏随机猜测的期望水平。这种系统性的全面失效并非偶然，而是由传统序列推荐算法的核心机理与本任务中极端稀疏的对话交互模式之间，存在不可调和的内在矛盾所导致的，具体可从以下两个深层维度进行机理剖析：

首要根源在于长尾分布导致的 Item ID 嵌入空间梯度稀疏与泛化瓶颈。无论是利用门控机制捕获短期时序转移的 GRU4Rec，还是通过多头自注意力机制构建全局依赖的 SASRec，其底层的数学基石均严重依赖于一个高度参数化的条目稠密嵌入矩阵。然而，深入分析

TalkPlay 语料库的统计特性可以发现，数据集中存在着极端的长尾效应，有超过半数的候选曲目在全局训练集中的有效交互频次仅为单次。这意味着，在模型执行端到端的反向传播时，这些海量长尾条目的 ID 嵌入向量，在整个训练周期内实质上仅接受到了极少数甚至是一次极其微弱的梯度更新。在缺乏足够长尾协同信号进行流形约束的前提下，这些向量根本无法在稠密向量空间中实现收敛，最终其表征实质上仍滞留于随机初始化的噪声状态。当模型在精排或打分阶段试图将 Query 状态向量与这些退化为噪声的 ID 向量进行点积检索时，不可避免地会产生严重的输出失真。

另一核心机理在于极短会话特征引发的转移概率矩阵退化与序列稀疏性。传统序列模型之所以在电商、短视频等传统流媒体场景中大放异彩，是因为那些场景的用户 Session 通常蕴含数十乃至上百次连续的点击流，模型借此能有效构建出高阶的马尔可夫转移概率链。但在 TalkPlay 对话式音乐推荐这一特定商务语境中，用户单次 Session 内由“MOVES_TOWARD_GOAL”标签定义的有效交互轮次极为短促。在这种极端的短序列约束下，可供模型进行滑窗或自注意力矩阵计算的上下文滑动窗口实质上发生了严重失真。对于 SASRec 而言，极短的交互历史导致其注意力机制退化为对孤立节点的权值平摊，根本无法利用多头机制去解耦用户长期的、深层的音乐品味偏好；对于 GRU4Rec 而言，隐状态h_t尚未经过充分的时序迭代便被迫进行输出映射，导致其循环单元的动态记忆能力陷入无法运行的困境。

综上所述，传统序列模型由于过分绑定条目 ID 的协同显式共现，导致其在面临长尾冷启动曲目与短对话序列时失效。这一实验发现强有力地论证了本文提出的舍弃显式 ID 依赖、利用大模型微调 Thought 语义作为中间桥梁的两阶段架构在突破对话式推荐底层稀疏性瓶颈上的重大理论意义与商业应用价值。

4.2 语义检索范式的优势验证

Stage 1 的核心设计选择是不依赖 Item ID 嵌入，转而使用 thought 文本的稠密语义表示，这从根本上规避了长尾曲目的表示学习瓶颈。原始 MiniLM 的零样本 MRR 为 0.064（平均排名约第 16 名），而经过面向领域的 InfoNCE 对比学习微调后，MRR 跃升至 0.136（平均排名约第 7 名），提升 113%。

这一提升的关键在于：对比学习将对话上下文的非正式偏好表述与 thought 文本中蕴含的专业音乐描述在嵌入空间中显式对齐。微调后的编码器学到的不是具体的曲目 ID 偏好，而是语义偏好到音乐特征描述的跨语言映射能力。这使得模型能够泛化到任何拥有 thought 文本的曲目，不论该曲目在训练集中的出现频次如何。

4.3 精排阶段的增量贡献

Stage 2 的演进历程揭示了一个关键的方法论启示：在多阶段推荐系统中，各级之间的候选分布对齐比模型复杂度更重要。

初版 Stage 2 使用随机负采样训练（每样本 19 个随机负例），训练与评估之间存在严重的分布失配。模型在训练阶段学到的是"从 46K 曲目中区分 20 个随机候选"，而评估阶段面对的是 Stage 1 精挑细选的 200 个高度相似候选。这种失配导致模型验证 MRR 仅 0.083，甚至低于 Stage 1 自身（0.136）。

将训练候选集切换为 Stage 1 的真实 Top-200 检索结果后，训练与评估的候选分布实现了完全对齐。在这一条件下，Stage 2 的 Cross-Attention 精排模型有效发挥了多模态融合的

能力：将用户偏好嵌入、历史播放约束与候选曲目音频-语义特征进行非线性交互建模，并通过 LambdaRank 损失直接优化排序质量。最终两阶段 MRR 达到 0.2745，比 Stage 1 单独提升了 102%；Hit@1 从 6.14%跃升至 20.10%，意味着每 5 次推荐中有 1 次第一首歌即为正确答案。

4.4 消融演进总览

表 5 汇总了从零样本基线到最终两阶段系统的完整消融演进路径

表 5 消融演进路径（6,184 条测试正例）

阶段	MRR	NDCG@10	Hit@1	Hit@10	增量贡献
MiniLM 零样本	0.064	—	—	—	—
+InfoNCE 微调（=Stage 1）	0.136	0.164	6.14%	29.17%	MRR+113%
+Cross-Attention 随机负例	0.083	—	—	—	MRR-39%（退化）
+训练/评估分布对齐	0.224	—	—	—	MRR+170%
+LambdaRank+防过拟合（最终）	0.275	0.294	20.10%	41.30%	—

从表中可以清晰看到：InfoNCE 微调带来了语义层面的首次大幅提升；训练和评估分布对齐是实现 Stage 2 价值的必要条件；LambdaRank 与正则化调参在此基础之上贡献了最后的 20%增量。

4.5 局限性与未来方向

尽管两阶段架构在所有指标上取得了显著领先，当前系统仍存在以下局限值得后续探索。

目前 Stage 1 的 MiniLM 微调与 Stage 2 的 Cross-Attention 精排为分离式训练，两个阶段的梯度无法相互传导。Stage 2 的精排反馈无法反向优化 Stage 1 的嵌入空间。后续可探索将两阶段纳入统一的端到端训练框架，使精排损失指导粗排编码器的优化方向。

当前 thought 索引覆盖 46,454 首曲目，而 track embedding 总计 47,071 首，存在约 600 首曲目缺乏 thought 文本。测试集中有 45 条约 0.7%的样本因此无法参与评估。可通过训练一个小型 MLP（audio 512d→thought 384d），在有 thought 数据的曲目上以 MSE 训练，为缺失曲目补全语义嵌入。

User-Metadata 数据集提供了 8,772 名用户的年龄组、性别与国籍信息，目前未被任何模型利用。在 test_cold 用户的无 CF-BPR 嵌入覆盖场景下，demographic 特征可作为协同过滤嵌入的 fallback，有望改善冷启动推荐的基线表现。

当前 context_text 的构建方式为简单的对话文本拼接，未区分 user 与 assistant 的不同对话角色。引入角色感知的对话编码 user utterance 与 system response 分别编码后交叉注意力，可能进一步捕获对话交互中的隐式偏好转移信号。

项目贡献：

	肖鸿涛	覃义程	王路轩	肖鸿杰
选题确定+选题报告撰写（5%）	2%	1%	1%	1%
主要模型设计（25%）	25%			
参考模型（35%）	5%（LR）	10%（SASRec）	10%（GRU4Rec）	10%（BERT4Rec）
PPT 制作（10%）	2%	8%		
视频录制（15%）	3.75%	3.75%	3.75%	3.75%
项目论文撰写（10%）	10%			
汇总	47.75%	22.75%	14.75%	14.75%